

بسم الله الرحمن الرحيم

سوال ۱

؟ تفاوتی چه Supervised Learning و Unsupervised Learning

تفاوت اصلی بین یادگیری نظارت شده (Supervised Learning) و یادگیری بدون نظارت (Unsupervised Learning) در این است که:

یادگیری نظارت شده: با استفاده از داده‌های برچسب‌دار (یعنی داده‌هایی که ورودی و خروجی مشخصی دارند) یک الگو یاد می‌گیرد تا بتواند خروجی را برای ورودی‌های جدید پیش‌بینی کند.

یادگیری بدون نظارت: با استفاده از داده‌های بدون برچسب، الگوها و ساختارهای پنهان در داده‌ها را کشف می‌کند. هدف آن پیش‌بینی خروجی نیست، بلکه درک بهتر داده‌ها است.

سوال ۲

B. چرا Scaling Feature در الگوریتم‌های Learning Machine ضروری است؟

مقیاس‌بندی ویژگی‌ها (Feature Scaling) در الگوریتم‌های یادگیری ماشین به این دلایل ضروری است:

بهبود سرعت همگرایی: الگوریتم‌ها سریع‌تر به جواب بهینه می‌رسند.

جلوگیری از تسلط ویژگی‌های با مقیاس بزرگ: ویژگی‌های با مقیاس بزرگ‌تر می‌توانند بر ویژگی‌های با مقیاس کوچک‌تر غلبه کنند و الگوریتم را به سمت نتایج نادرست هدایت کنند.

بهبود دقت: با مقیاس‌بندی مناسب، الگوریتم می‌تواند الگوهای پنهان را بهتر شناسایی کند و دقت مدل را افزایش دهد.

سوال ۳

C. Standardization و Normalization چه تفاوتی دارند؟

هر دو استانداردسازی (Standardization) و نرمال‌سازی (Normalization) روش‌هایی برای مقیاس‌بندی ویژگی‌ها هستند، اما تفاوت کلیدی دارند:

استانداردسازی (z-score normalization): داده‌ها را به طوری مقیاس‌بندی می‌کند که میانگین آن‌ها صفر و انحراف معیار آن‌ها یک شود.

نرمال‌سازی (min-max scaling): داده‌ها را به بازه مشخصی (معمولاً بین 0 تا 1) مقیاس‌بندی می‌کند.

انتخاب بین این دو به الگوریتم یادگیری ماشین و ویژگی‌های داده‌ها بستگی دارد.

سوال ۴

D. چرا Normalization Max-Min برای مقیاس‌بندی داده‌ها استفاده می‌شود؟

نرمال‌سازی Min-Max برای مقیاس‌بندی داده‌ها استفاده می‌شود زیرا:

ساده و قابل فهم است: داده‌ها را به بازه‌ای مشخص (معمولاً 0 تا 1) تبدیل می‌کند.

حفظ ساختار داده: نسبت‌های بین مقادیر را حفظ می‌کند.

مناسب برای الگوریتم‌های حساس به مقیاس: مانند الگوریتم‌های مبتنی بر فاصله (K-NN، K-Means) و شبکه‌های عصبی.

سوال ۵

Normalization Score-Z. چیست و چرا کاربرد دارد؟

نرمال‌سازی Z-Score (استانداردسازی) روشی است برای مقیاس‌بندی داده‌ها با استفاده از میانگین و انحراف معیار. در این روش، هر مقدار به صورت زیر محاسبه می‌شود:

$$Z = \frac{X - \mu}{\sigma}$$

که در آن  $\|X\|$  مقدار اصلی،  $\|\mu\|$  میانگین و  $\|\sigma\|$  انحراف معیار است.

کاربردها:

1. حذف تأثیر مقیاس: به داده‌ها مقیاس یکسان می‌دهد و آن‌ها را به توزیع استاندارد تبدیل می‌کند.
2. بهبود عملکرد الگوریتم‌ها: برای الگوریتم‌هایی که به فاصله و توزیع داده‌ها حساس‌اند (مانند رگرسیون خطی و شبکه‌های عصبی) مفید است.
3. شناسایی نقاط دورافتاده: نقاطی که Z-Score آن‌ها بیش از 3 یا کمتر از -3 باشد، ممکن است به عنوان نقاط دورافتاده مشخص شوند.

سوال ۶

Machine Learning الگوریتم‌های در Regularization ؟

در یادگیری ماشین، روش‌های منظم‌سازی (Regularization) برای جلوگیری از بیش‌برازش (Overfitting) استفاده می‌شوند. دو روش اصلی عبارتند از:

- L1 Regularization (Lasso): ضرایب مدل را به سمت صفر می‌کشد و باعث انتخاب ویژگی می‌شود (بعضی ضرایب را به صفر می‌رساند).
- L2 Regularization (Ridge): ضرایب مدل را به سمت صفر می‌کشد، اما آن‌ها را به طور کامل به صفر نمی‌رساند.

هر دو روش با اضافه کردن یک جریمه به تابع هزینه مدل، پیچیدگی مدل را کاهش می‌دهند. انتخاب بین L1 و L2 به داده‌ها و مدل مورد استفاده بستگی دارد.

سوال ۷

Overfitting و Underfitting چه مشکلاتی را در building-Model به وجود می‌آورند؟

بیش برآزش (Overfitting): مدل بیش از حد به داده‌های آموزشی وابسته می‌شود و در داده‌های جدید عملکرد ضعیفی دارد. دلیل آن پیچیدگی بیش از حد مدل است.

کم برآزش (Underfitting): مدل نمی‌تواند الگوی داده‌ها را به خوبی یاد بگیرد و در داده‌های آموزشی و جدید عملکرد ضعیفی دارد. دلیل آن سادگی بیش از حد مدل است.

سوال ۹

؟ کاربرد Train/Test Split در چرا Cross-Validation

در روش اعتبارسنجی متقابل (Cross-Validation)، از تقسیم Train/Test برای ارزیابی دقیق‌تر عملکرد مدل استفاده می‌شود، به این صورت که:

جلوگیری از بیش‌برآزش: با ارزیابی مدل بر روی داده‌های تست دیده نشده، از بیش‌برآزش جلوگیری می‌شود.

ارزیابی پایدارتر: به جای یک بار ارزیابی، چندین بار با تقسیمات مختلف داده‌ها این کار انجام می‌شود و میانگین نتایج محاسبه می‌شود تا ارزیابی پایدارتری به دست آید.

انتخاب بهترین مدل: با مقایسه نتایج اعتبارسنجی متقابل برای مدل‌های مختلف، می‌توان بهترین مدل را انتخاب کرد.

سوال ۱۰

Descent Gradient چگونه کار میکند؟

گرادیان کاهشی (Gradient Descent) به طور خلاصه اینطوری کار می‌کند:

1. هدف: پیدا کردن کمترین نقطه یک تابع (معمولاً تابع هزینه در یادگیری ماشین).

2. روش کار:

محاسبه گرادیان: گرادیان جهت "شیب تندترین صعود" رو به ما نشون میده.

برداشتن یک قدم در جهت مخالف: ما یک قدم کوچک در جهت مخالف گرادیان برمی‌داریم تا به سمت "شیب تندترین نزول" حرکت کنیم. اندازه قدم رو "نرخ یادگیری" مشخص می‌کنه.

تکرار: این کار رو تا زمانی که به یک نقطه کمینه (یا نزدیک به اون) برسیم تکرار می‌کنیم.

به زبان ساده، مثل اینه که بخوای از بالای یک تپه پایین بیای. هر بار نگاه می‌کنی کدوم طرف سرازیری تندتره و یه قدم کوچیک در اون جهت برمی‌داری.

سوال ۱۱

چرا Learning Deep برای پیچیده‌ترین مسائل استفاده میشود؟

یادگیری عمیق (Deep Learning) به دلیل این موارد برای مسائل پیچیده‌تر استفاده می‌شود:

یادگیری ویژگی‌ها به طور خودکار: شبکه‌های عمیق می‌توانند ویژگی‌های پیچیده و انتزاعی را از داده‌ها به طور خودکار یاد بگیرند، بدون نیاز به مهندسی ویژگی دستی. مدل‌سازی سلسله مراتبی: لایه‌های متعدد شبکه‌های عمیق به مدل اجازه می‌دهند تا مفاهیم پیچیده را به صورت سلسله مراتبی و از طریق ترکیب ویژگی‌های ساده‌تر، درک کنند. ظرفیت مدل‌سازی بالا: شبکه‌های عمیق دارای تعداد زیادی پارامتر هستند که به آنها اجازه می‌دهد الگوهای پیچیده را در داده‌ها مدل کنند.

\*